

TINY+ 词法分析程序实验

- [TINY+ 词法分析程序实验](#)
 - [实验目的](#)
 - [实验内容](#)
 - [实验要求](#)
 - [实验环境](#)
 - [TINY+语言](#)
 - [实验过程](#)
 - [实验测试结果展示](#)
 - [心得体会](#)

实验目的

通过扩充已有的样例语言TINY语言的词法分析程序，为扩展TINY语言TINY + 构造词法分析程序，从而掌握词法分析程序的构造方法。

实验内容

了解样例语言TINY及TINY编译器的实现，了解扩展TINY语言TINY + ，用C/C++语言在已有的TINY词法分析器基础上扩展，构造TINY + 的词法分析程序。

实验要求

将TINY + 源程序翻译成对应的TOKEN序列，并能检查一定的词法错误。

实验环境

- **Linux(Ubuntu)**
- g++
- make

TINY+语言

1. TOKEN序列表现形式: (Kind,Value)

其中, Kind为词的种类, Value表示词的实际值。下面是Kind的种类:

KEY	SYM	ID	NUM	STR
关键字	特殊符号	标识符	数字常量	字符串常量

2. 关键字:

Tiny关键字	if then else end repeat until read write
Tiny+新增关键字	Or and int bool string while do true false not

其中所有的关键字是程序设计语言保留使用的, 并且用小写字母表示, 用户自己定义的标识符不能和关键字重复。

3. 特殊符号:

Tiny符号	{ } ; := + - * / () < =
Tiny+新增符号	> <= >= , '

4. 词法分析

○ 词法要求

- 关键词必须以字母开头
- 字符不能包含在数字中
- 注释用方括号括起来, 不能嵌套, 但可以包含不止一行
- 字符串用单引号括起来
-

○ 错误检查

- ALPHA_AFTER_NUMBER_ERROR 字母紧接数字错误
- ASSIGN_LEXICAL_ERROR 赋值符号没有打全错误
- SINGLE_QUOTES_MISSING_FOR_STRING_ERROR 字符串缺失单引号错误
- LEFT_BRACE_MISSING_FOR_COMMENTS_ERROR 注释左大括号缺失错误
- RIGHT_BRACE_MISSING_FOR_COMMENTS_ERROR 注释右大括号缺失错误
- ILLEGAL_CHARACTER非法字符
-

实验过程

1. 在声明全局变量的global.h文件中枚举TOKEN类型, 分别包括上面所述的五大种类, 细分下来36种之多, 如下图:

```

typedef enum
{
    ENDFILE,
    ERROR,
    /**Reversed Tokens**/
    TK_TRUE,    //true
    TK_FALSE,   //false
    TK_OR,      //or
    TK_AND,     //and
    TK_NOT,     //not
    TK_INT,     //int
    TK_BOOL,    //bool
    TK_STRING,  //string
    TK_WHILE,   //while
    TK_DO,      //do
    TK_IF,      //if
    TK_THEN,    //then
    TK_ELSE,    //else
    TK_END,     //end
    TK_REPEAT,  //repeat
    TK_UNTIL,   //until
    TK_READ,    //read
    TK_WRITE,   //write

    /**Multi-character tokens**/
    ID,         //标识符
    NUM,        //数字
    STRING,     //字符串常量
    /**Special Symbols**/
    TK_GTR,     // >
    TK_LEQ,     // <=
    TK_GEQ,     // >=
    TK_COMMA,   // ,
    TK_SEMICOLON, // ;
    TK_ASSIGN,  // :=
    TK_ADD,     // +
    TK_SUB,     // -
    TK_MUL,     // *
    TK_DIV,     // 除号
    TK_LP,      // (
    TK_RP,      // )
    TK_LSS,     // <
    TK_EQU      // ==
} TokenType;

```

2. 在词法分析程序实现文件scan.cpp中实现词法分析状态机以及关键字枚举等。如下图：

```

/**
 * @struct 关键字表
 * @brief 其中, str关键字的字符串表示, tok为关键字对应的TOKEN类型
 * **/
static struct
{
    std::string str;
    TokenType tok;
} reversedWords[MAXRESERVED] = {
    {"if", TK_IF},
    {"true", TK_TRUE},
    {"false", TK_FALSE},
    {"or", TK_OR},
    {"and", TK_AND},
    {"not", TK_NOT},
    {"int", TK_INT},
    {"bool", TK_BOOL},
    {"string", TK_STRING},
    {"while", TK_WHILE},
    {"do", TK_DO},
    {"then", TK_THEN},
    {"else", TK_ELSE},
    {"end", TK_END},
    {"repeat", TK_REPEAT},
    {"until", TK_UNTIL},
    {"read", TK_READ},
    {"write", TK_WRITE}};

/**
 * @enum STATE
 * @brief 有限状态机的状态集
 * **/
typedef enum
{
    START,
    INID,
    INNUM,
    INCOMMENT,
    INASSIGN,
    INLEQ,
    INGEQ,
    INSTR,
    SUCCESS,
    FAILED
} STATE;

```

实现关键字表的查询函数，方便使用，其实就是遍历即可

```

/**
 * @brief 查询关键字表
 * @details 当获得了一个ID类型的token之后，还需要调用此函数进行判断其是不是关键字，如果是，就返回其对应的关键字TOKEN类型
 * @param 该ID类型token的字符串表示
 * @return 如果是关键字，返回对应的TOKEN类型；如果不是，直接返回ID即可。
 * **/
static TokenType reversedLookUp(const std::string &s)
{
    for (auto &i : reversedWords)
    {
        if (i.str == s)
            return i.tok;
    }
    return ID;
}

```

接下来就是实现词法分析最关键的函数getToken，读取行然后输出以pair作为表示的TOKEN序列，下面给出部分函数片段(详见scan.cpp文件)：

声明函数所需的中间变量：

```

/**
 * @brief 获取TOKEN函数，词法分析的核心算法
 * @param ret_lineno out 用于返回值，token对应的行号
 * @return std::pair类型，其中第一个元素为读取到的TOKEN类型，第二个元素为token对应的字符串表示
 * **/
std::pair<TokenType, std::string> getToken(int &ret_lineno)
{
    bool isNeedToSave;
    TokenType currToken;
    std::string tokenString;
    bool is_unget; //是否已经出现了回滚操作

    /**
     * 一开始处于START状态
     * @update 如果大括号栈中还有东西，应让它处于注释状态（错误处理）
     * **/
    STATE state = (brace_num_nested == 0 ? START : INCOMMENT);

```

循环只当词法分析状态为成功或者失败时跳出，且用一个switch将每种状态的情况罗列出来，分情况来实现：

```

while (state != SUCCESS && state != FAILED)
{ //如果仍不处于终态
    char c = getNextChar();
    isNeedToSave = true;
    is_unget = false;
    switch (state)
    {
        /** 初始状态**/
        case START:
            if (isdigit(c))
                state = INNUM; // 转移状态到IN数字
            else if (isalpha(c))
                state = INID; // 转移状态到IN标识符
            else if (c == ':')
                state = INASSIGN;
            else if (c == ' ' || c == '\t' || c == '\n')
                isNeedToSave = false;
            else if (c == '{')
            {
                isNeedToSave = false;
                state = INCOMMENT;
            }
            else if (c == '}')
            {
                //FIXME-1:ERROR
                isNeedToSave = false;
                state = FAILED;
            }
    }
}

```

处理注释:

```

        /** 注释状态**/
        case INCOMMENT:
            isNeedToSave = false;
            if (c == EOF)
            {
                /*state = SUCCESS; //TODO |
                currToken = ENDFILE;*/
                //FIXME 如果读到文本终止符, 意味着这个文本并没有存在右大括号符, 此时应该及时返回并把终止符吐回去
                state = FAILED;
                currToken = ERROR;
                tokenString = error_items[RIGHT_BRACE_MISSING_FOR_COMMENTS_ERROR].error_description;
                ungetNextChar();
            }
    }
}

```

处理数字:

```

    /**数字状态**/
case INNUM:
    if (isalpha(c))
    { //当数字紧接字母的时候, 是错误的
        ungetNextChar();
        is_unget = true;
        isNeedToSave = false;

        state = FAILED;
        currToken = ERROR;
        tokenString = error_items[0].error_description;
    }
    else if (!isdigit(c))
    {
        state = SUCCESS;
        currToken = NUM;
        ungetNextChar();
        is_unget = true;
    }
    break;

```

还有很多代码, 此处不一一展示, 详见scan.cpp, 重要部分均给出注释。

3. 在输出TOKEN序列实现函数的print.cpp文件中, 实现printToken函数来输出Token序列, 实现也不难, 由于函数较长, 仅展示部分如下(详见print.cpp):

```

void printToken(TokenType token, const char *tokenString, const int &lineno)
{
    switch (token)
    {
        case TK_TRUE:
        case TK_FALSE:
        case TK_OR:
        case TK_AND:
        case TK_NOT:
        case TK_INT:
        case TK_BOOL:
        case TK_STRING:
        case TK_WHILE:
        case TK_DO:
        case TK_IF:
        case TK_THEN:
        case TK_ELSE:
        case TK_END:
        case TK_REPEAT:
        case TK_UNTIL:
        case TK_READ:
        case TK_WRITE:
            fprintf(listing, "(KEY, %s)\n", tokenString);
            break;
        case TK_GTR:
            fprintf(listing, "(TK_GTR, >)\n");
            break;
    }
}

```

```

case TK_LP:
    fprintf(listing, "(TK_LP, ())\n");
    break;
case TK_RP:
    fprintf(listing, "(TK_RP, ))\n");
    break;
case TK_LSS:
    fprintf(listing, "(TK_LSS, <)\n");
    break;
case TK_EQU:
    fprintf(listing, "(TK_EQU, =)\n");
    break;
case ID:
    fprintf(listing, "(ID, %s)\n", tokenString);
    break;
case NUM:
    fprintf(listing, "(NUM, %s)\n", tokenString);
    break;
case ERROR:
    fprintf(listing, "\033[1;31mAn Error is detected at line %d: %s \033[0m\n", lineno, tokenString);
    break;
case STRING:
    fprintf(listing, "(STR, %s)\n", tokenString);
    break;
default:
    fprintf(listing, "Unknown token: %d\n", token);
}

```

同时，定义输出error的函数printError，可以将error的输出弄成红色。

```

void printError(const int &error_code, const int &lineno, char *error_details)
{
    if (listing == stdout) //输出到控制台可以带有颜色
        fprintf(listing, "\033[1;31mAn Error is detected at line %d: %s \033[0m\n", lineno,
            error_items[error_code].error_description.c_str());
    else
        fprintf(listing, "An Error is detected at line %d: %s\n", lineno,
            error_items[error_code].error_description.c_str());
}

```

4. main中处理输出方式，支持输出到控制台(屏幕)或文件中。

```

if (argc >= 2)
//if (argc >= 3 && !strcmp(argv[2], "tokens"))
{
    //仅输出token
    if (argc > 2) //if(argc>3)
        listing = fopen("tokens", "w");
    else
        listing = stdout;
    fprintf(listing, "TOKENS序列: \n");
    do
    {
        int line = 0;
        auto tmp = getToken(line);
        if (tmp.first == ENDFILE)
            break;
        printToken(tmp.first, tmp.second.c_str(), line);
    } while (true);
    std::cout << "DONE" << std::endl;
    return 0;
}

```

实验测试结果展示

- 输入make得到可执行程序main，并在命令行输入参数运行，测试Tiny源程序以及输出TOKEN序列如下图（测试test.tny）：

test.tny X

test.tny

```

1  if then else end repeat until read write
2  or and int bool string while do true false not
3  {  } ; := + - * / ( ) < =
4  > <= >= ,
5  gzy28 123 'gzy'
6

```

```
root@DESKTOP-6L638NB:/mnt/e/code/Compiler/tiny# make
```

```
g++ -lpthread -lm -Iinclude -g -w src/generate.cpp src/main.cpp src/parser.cpp src/print.cpp src/scan.cpp -o bin/main
```

```
root@DESKTOP-6L638NB:/mnt/e/code/Compiler/tiny# ./bin/main test.tny
```

TOKENS序列:

```

(KEY, if)
(KEY, then)
(KEY, else)
(KEY, end)
(KEY, repeat)
(KEY, until)
(KEY, read)
(KEY, write)
(KEY, or)
(KEY, and)
(KEY, int)
(KEY, bool)
(KEY, string)
(KEY, while)
(KEY, do)
(KEY, true)
(KEY, false)
(KEY, not)
(TK_SEMICOLON, ;)
(TK_ASSIGN, :=)
(TK_ADD, +)
(TK_SUB, -)
(TK_MUL, *)
(TK_DIV, /)
(TK_LP, ()
(TK_RP, ))
(TK_LSS, <)
(TK_EQU, =)
(TK_GTR, >)
(TK_LEQ, <=)
(TK_GEQ, >=)
(TK_COMMA, ,)
(ID, gzy28)
(NUM, 123)
(STR, 'gzy')
DONE

```

可以看到每种Tiny原来的关键字或特殊符号或字符串等以及新增的均能被识别出来。

- 接下来测试正常的Tiny程序，如下图（test2.tny）：

test2.tny X

test2.tny

```

1  int x,fact,A,B,C,D;
2  {This is a comment.}
3  read x;
4  if x < 10 and x > 5 or x < 9 then
5  |   fact := 4
6  |   else
7  |   fact := 6
8  |   end;
9
10 repeat
11 |   A:=A*2;
12 until (A+C) < (B+D);
13
14 while (A+B+C) < 10 do
15 |   B := B + 3;
16 end

```



```
root@DESKTOP-6L638NB:/mnt/e/code/Compiler/tiny# ./bin/main test2.tny
TOKENS序列:
(KEY, int)
(ID, x)
(TK_COMMA, ,)
(ID, fact)
(TK_COMMA, ,)
(ID, A)
(TK_COMMA, ,)
(ID, B)
(TK_COMMA, ,)
(ID, C)
(TK_COMMA, ,)
(ID, D)
(TK_SEMICOLON, ;)
(KEY, read)
(ID, x)
(TK_SEMICOLON, ;)
(KEY, if)
(ID, x)
(TK_LSS, <)
(NUM, 10)
```

此处由于输出序列较长仅展示一部分，详见tokens文件。

- 在./bin/main test2.tny 加上 tokens 可以将结果输出到一个名为tokens的文件。

```
root@DESKTOP-6L638NB:/mnt/e/code/Compiler/tiny# ./bin/main test2.tny tokens
DONE
```

```
tokens
tokens
1  TOKENS序列:
2  (KEY, int)
3  (ID, x)
4  (TK_COMMA, ,)
5  (ID, fact)
6  (TK_COMMA, ,)
7  (ID, A)
8  (TK_COMMA, ,)
9  (ID, B)
10 (TK_COMMA, ,)
11 (ID, C)
12 (TK_COMMA, ,)
13 (ID, D)
14 (TK_SEMICOLON, ;)
```

(仅展示部分，详见具体文件)

- 测试词法错误
注释括号未打全：

```
test2.tny X
test2.tny
1  int x,fact,A,B,C,D;
2  {This is a comment.}
3  read x;
4  if x < 10 and x > 5 or x < 9 then
5  |   fact := 4
6  else
7  |   fact := 6
8  end;
9
10 repeat
11 |   A:=A*2;
12 until (A+C) < (B+D);

问题 输出 调试控制台 终端

root@DESKTOP-6L638NB:/mnt/e/code/Compiler/tiny# ./bin/main test2.tny
TOKENS序列:
(KEY, int)
(ID, x)
(TK_COMMA, ,)
(ID, fact)
(TK_COMMA, ,)
(ID, A)
(TK_COMMA, ,)
(ID, B)
(TK_COMMA, ,)
(ID, C)
(TK_COMMA, ,)
(ID, D)
(TK_SEMICOLON, ;)
An Error is detected at line 16: The right brace is missing
DONE
```

变量命名数字在字母前面:

```
test2.tny X
test2.tny
1  int 222x,fact,A,B,C,D;
2  {This is a comment.}
3  read x;
4  if x < 10 and x > 5 or x < 9 then

问题 输出 调试控制台 终端 1: bash

root@DESKTOP-6L638NB:/mnt/e/code/Compiler/tiny# ./bin/main test2.tny
TOKENS序列:
(KEY, int)
An Error is detected at line 1: Numbers cannot be followed by letters.
(ID, x)
(TK_COMMA, ,)
(ID, fact)
(TK_COMMA, ,)
(ID, A)
(TK_COMMA, ,)
(ID, B)
```

出现非法字符:



```
test2.tny X
test2.tny
1  int x,fact,A,B,C,D;
2  ¥%.....& (
3  {This is a comment.}
4  read x;
5  if x < 10 and x > 5 or x < 9 then
6  |   fact := 4
7  else
8  |   fact := 6
9  end;

问题 输出 调试控制台 终端

(TK_COMMA, ,)
(ID, B)
(TK_COMMA, ,)
(ID, C)
(TK_COMMA, ,)
(ID, D)
(TK_SEMICOLON, ;)
An Error is detected at line 2: Meet An Illegal Character
An Error is detected at line 2: Meet An Illegal Character
An Error is detected at line 2: Meet An Illegal Character
An Error is detected at line 2: Meet An Illegal Character%
An Error is detected at line 2: Meet An Illegal Character
An Error is detected at line 2: Meet An Illegal Character
An Error is detected at line 2: Meet An Illegal Character
An Error is detected at line 2: Meet An Illegal Character
An Error is detected at line 2: Meet An Illegal Character
An Error is detected at line 2: Meet An Illegal Character&
An Error is detected at line 2: Meet An Illegal Character
An Error is detected at line 2: Meet An Illegal Character
An Error is detected at line 2: Meet An Illegal Character
(KEY, read)
```

本词法分析程序还能检查字符串 ' 缺失以及赋值符号缺失等等问题，此处就不一一展示，略占篇幅，欢迎尝试。

心得体会

词法分析程序实现的难点还是在于getToken函数的实现，根据读取到的token，查询关键字表判断是否为关键字然后确定其类型，进行输出。其次就是词法分析错误的判断，在errors中声明了多种错误，然后在getToken中进行相应的判断，当注释的左 { 大括号时，应该判断接下来的token中有没有右大括号，若直至终止符都没有右大括号，那么应该输出错误。经过这次实验，我对词法分析的实现有了更深的理解，并实现了从课堂理论知识到实际应用实现的映射，获益匪浅。